Reinforcement Learning
Wprowadzenie

Jeremi Kaczmarczyk
Rafał Nowak
Piotr Semberecki

by Tooploox AI

Agenda:

1. Program / Agenda
2. Wprowadzenie do OpenAI
3. Gra ?????
4. Metody Monte Carlo
5. Temporal Difference Learning

Cele tego szkolenia

» Zapoznanie z tematem Reinforcement Learningu

» Zapozananie z technikami

» Stworzyć okazje do zaprogramowania podstawowych algorytmów/technik RL

Zasady:

» Prezentacja (hangout - view) + ludzie zdalni będą zmutowani podczas rozwiązywania zadań a w przerwach pomiędzy zadaniami mamy czas na dyskusję i wtedy będziemy ich odblokowywali

» Colab - jupyter Google:

» Slack kanał #rl-workshop

Reinforcement Learning

“Reinforcement Learning - jest to uczenie co zrobić - jak dopasować sytuacje do akcji aby zmaksymalizować numeryczny sygnał nagrody”

» Reinforcement Learning: An Introduction 2nd ed.

State - Stan

$$s, s', s_t$$

Stan określamy symbolem s i jest to obecna sytuacja w jakiej znajduje się środowisko. Jako s' oznaczamy stan będący rezultatem stanu s, natomiast s_t jest to stan dla danego kroku.

Action - Akcja

$$a, a_t$$

Znajdując się w stanie s możemy wykonać akcję a. Akcja powoduję zmianę stanu z s do s'.

Reward - Nagroda

$$r, r_t$$

Po wykonaniu akcji otrzymujemy nagrodę r od środowiska. Nagrodę otrzymujemy po każdym kroku i niekoniecznie jest pozytywna. Projektowanie sygnału nagrody ma kluczowe znaczenie przy rozwiązywaniu problemów Reinforcement Learningiem.

Policy - Polityka

$$\pi, \pi(s), \pi(a|s)$$

Polityka definiuje zachowanie w danym momencie. Jest to funkcja parametryzowana zwykle stanem lub parą stan-akcja. W przypadku prostych problemów jest to zwykle słownik. Zwraca akcję którą agent powinien wykonać w danym stanie albo prawdopodobieństwa wykonania każdej z akcji.

Value - Wartość

$$v_\pi(s), q_\pi(s, a)$$

Wartość określana jest w stosunku do danej polityki π. Określana jako v jeśli jest to wartość dla stanu, albo q jeśli dla pary stan-akcja. Jest to numeryczna wartość określająca jak dobrze jest być w danym stanie albo inaczej jaka jest średnia skumulowana nagroda możliwa w danym stanie lub dla danej pary stan-akcja.

Agent – Środowisko

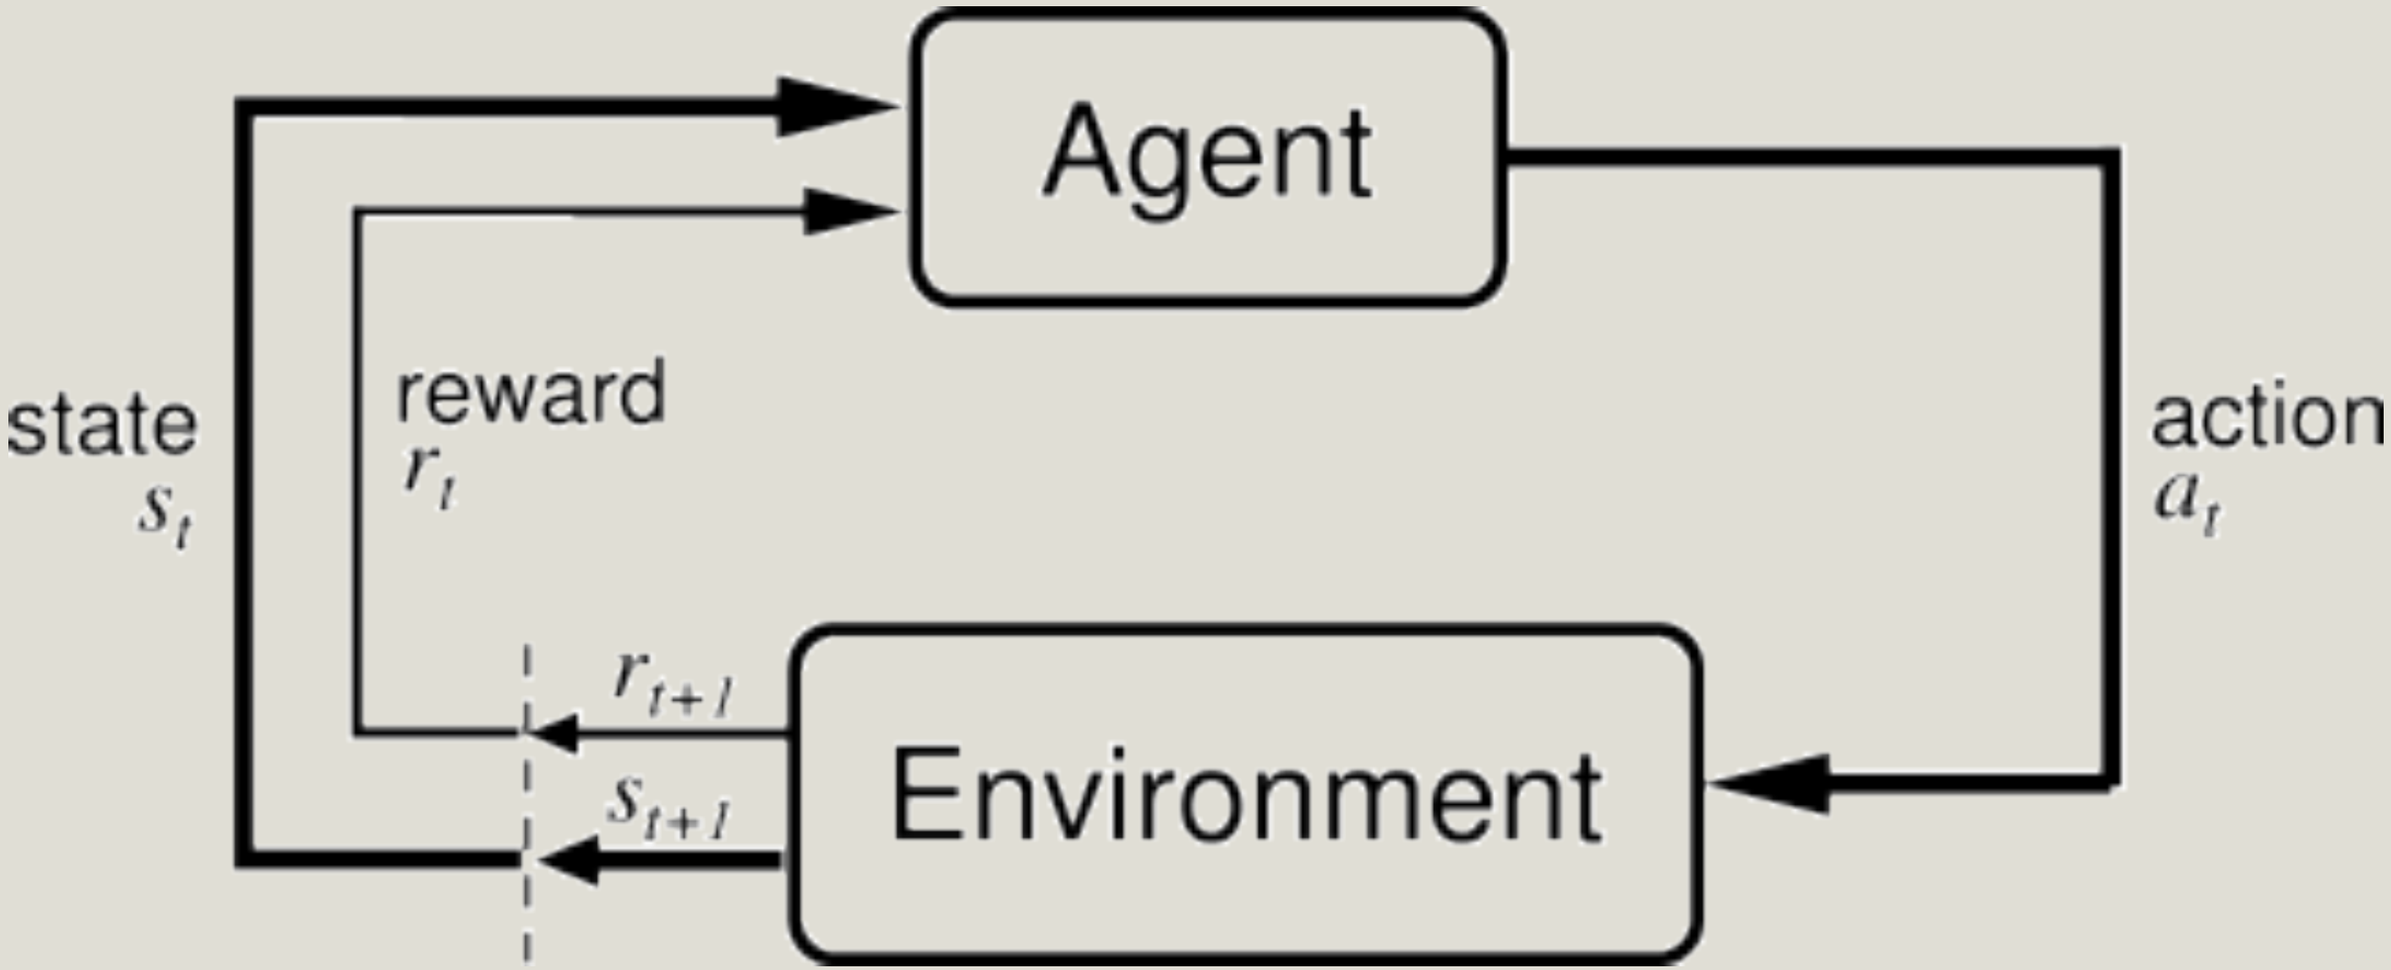

Taxi

- : możemy przejść, przez | nie
- R, G, Y, B miejsca podnoszenia / zostawienia pasażerów
- +20 nagrody za sukces
- -10 nagrody za nielegalne podniesienie / zostawienie
- -1 nagrody za każdy ruch

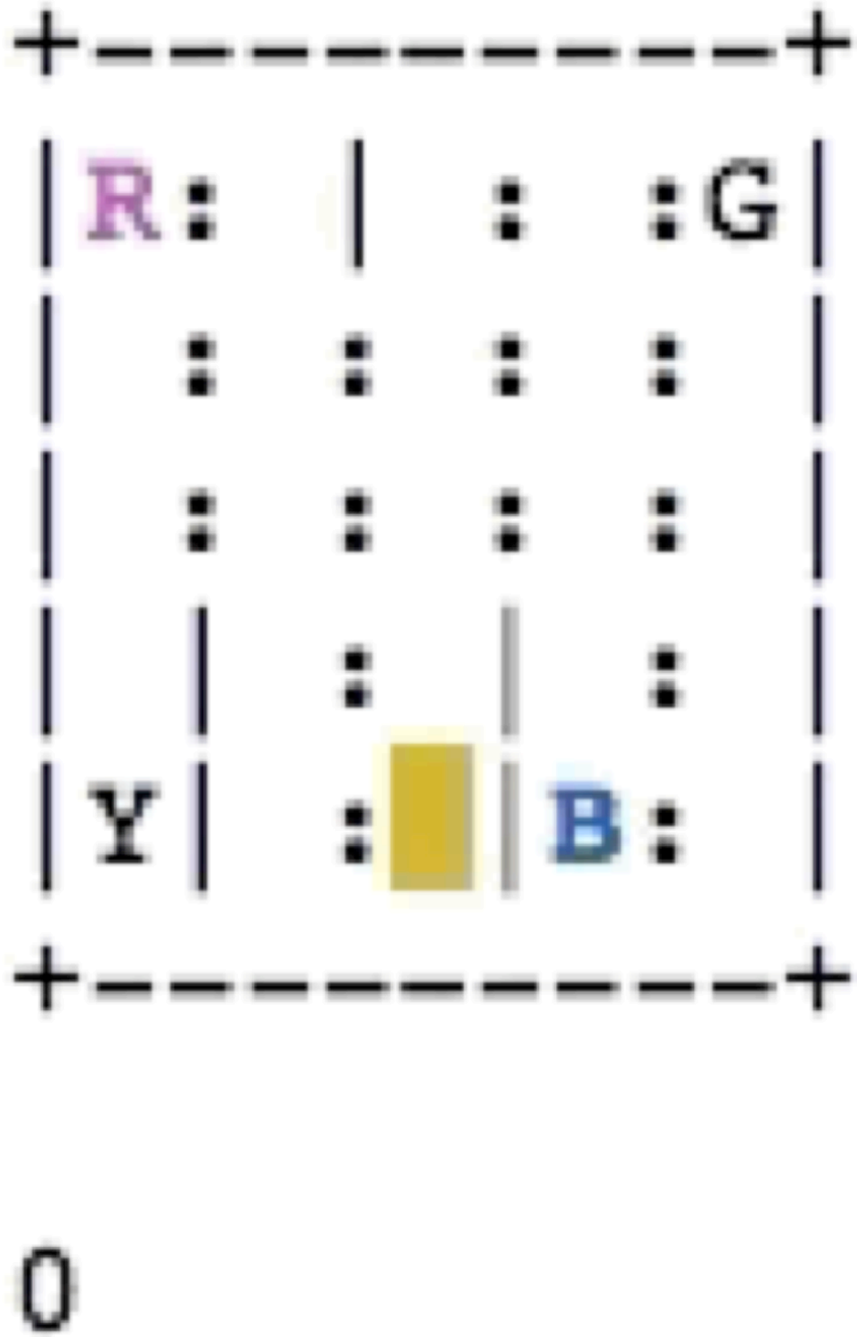

0

Markov Decision Process - MDP

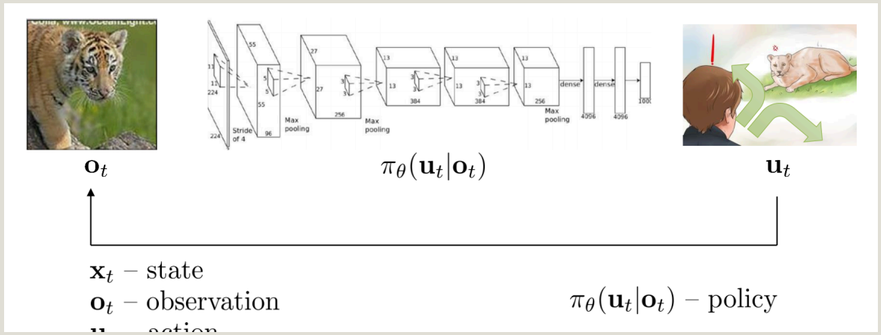

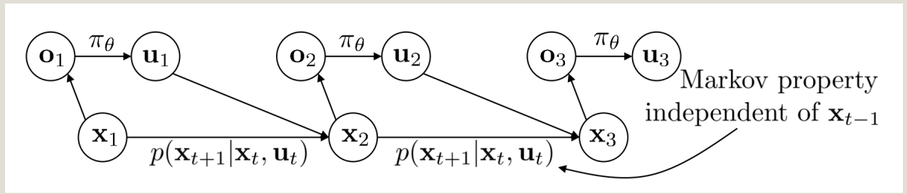

Markov Decision Process - MDP

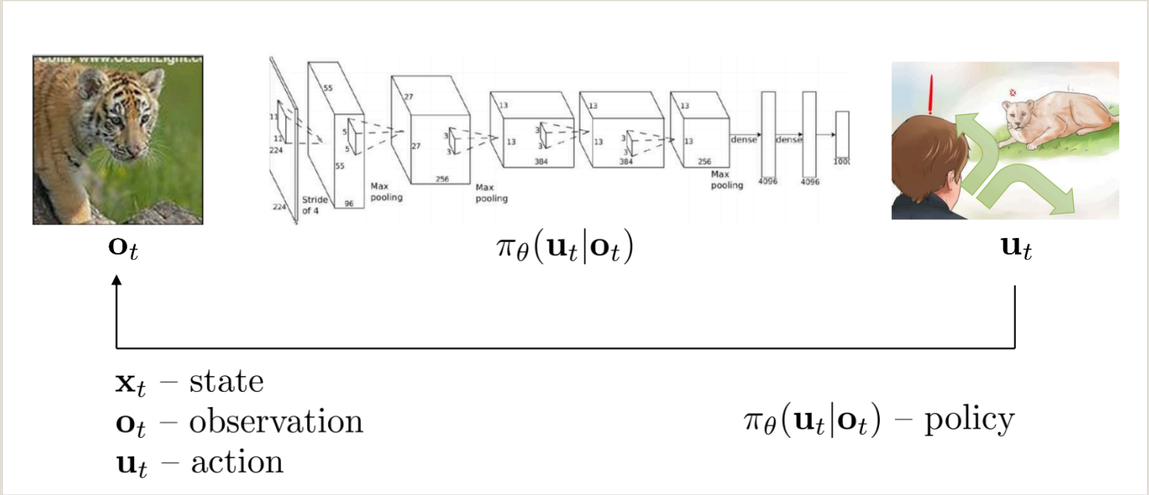

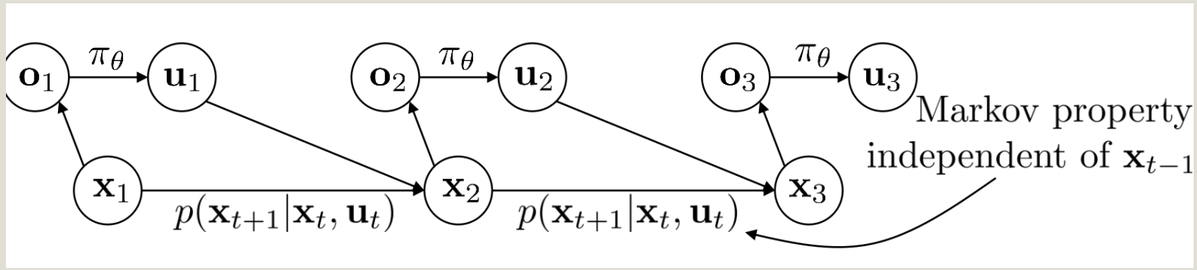

OpenAI Gym

“Gym is a toolkit for developing and comparing reinforcement learning algorithms. It supports teaching agents everything from walking to playing games like Pong or Pinball.”

» Gym website https://gym.openai.com

Installing

```
pip install gym
```

OpenAI Gym

```
done = False
while not done:
    env.render()
    time.sleep(.5)
    clear_output(True)
    observation, reward, done, info = env.step(env.action_space.sample())
```

```
+---------+
|R: | : :G|
| : : : : |
| : : : : |
| | : | : |
|Y| : |B: |
+---------+
  (South)
```

First Visit Monte Carlo Predicion

First Visit Monte Carlo Predicion

Input: `policy`

Output: `state-action dictionary Q`

Initialize **N** - dictionary where keys are states and values are number of visits to states

Initialize **returns_sum** - dictionary where keys are states and values are total rewards gained for that state

for **given number of episodes**:

Generate whole **episode** (S0, A0, R1, S2, A2, ... ST) using **policy**

for every step **t (St, At, Rt)** in **episode**:

if **(St, At)** is first visit in **current episode**:

N(St, At) += 1

returns_sum(St, At) += Rt + sum of discouned future rewards

Q = returns_sum(s, a) / N(s, a)

return Q

First Visit Monte Carlo Control

First Visit Monte Carlo Control

Output: `state-action dictionary Q`

Initialize **N** - dictionary where keys are states and values are number of visits to states

Initialize **returns_sum** - dictionary where keys are states and values are total rewards gained for that state

for **given number of episodes**:

    epsilon = epsilon(i)

    policy = epsilon greedy policy(Q)

    Generate whole **episode** (S0, A0, R1, S2, A2, ... ST) using **policy**

    for every step **t (St, At, Rt)** in **episode**:

        if **(St, At)** is first visit in **current episode**:

            Q(St, At) += alpha * (sum of discouned future rewards - Q(St, At))

return Q

Exploration vs Exploitation

TD-Learning (SARSA)

SARSA

Input: `policy`, number of episodes, alpha, GLIE

Output: `state-action dictionary Q`

Initialize **Q** - with 0

for **given number of episodes**:

epsilon = **epsilon(i)**

Observe **S0**

Choose **action A0** using epsilon greedy policy based on **Q**

t = 0

repeat until terminal state:

Take action **At** and observe **Rt+1** and **St+1**

Choose **action At+1** using epsilon greedy policy based on **Q**

Q(St, At) += alpha ***(Rt+1 + gamma*** **Q(St+1, At+1) - Q(St, At))**

t += 1

return Q

TD-Learning (Q-Learning)

Q-Learning

Input: `policy`, number of episodes, alpha, GLIE

Output: `state-action dictionary Q`

Initialize **Q** - with 0

for **given number of episodes**:

    epsilon = **epsilon(i)**

    Observe **S0**

    t = 0

    repeat until terminal state:

        Choose **action At** using epsilon greedy policy based on **Q**

        Take action **At** and observe **Rt+1** and **St+1**

        Q(St, At) += alpha *(Rt+1 + gamma* argmax(Q(St, a)) - Q(St, At))

        t += 1

return Q